Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №5

По дисциплине: «ИАД»

Тема: «**Деревья решений**»

Выполнил:
Студент 4 курса
Группы ИИ-23
Романюк А. П.
Проверила:
Андренко К.В.

Брест 2025

Цель: На практике сравнить работу нескольких алгоритмов одиночного дерева решений, случайного леса и бустинга для деревьев решений.

Общее задание

1. Загрузить датасет по варианту;
2. Разделить данные на обучающую и тестовую выборки;
3. Обучить на обучающей выборке одиночное дерево, случайный лес и реализовать бустинг для решающих деревьев (AdaBoost, CatBoost, XGBoost);
4. Оценить точность каждой модели на тестовой выборке;
5. Сравнить результаты, сделать выводы о применимости каждого метода для данного набора данных.

Задание по вариантам

- **Задания:**
    1. Загрузите данные и стандартизируйте (Для деревьев стандартизация не нужна, на лекции же говорили) их;
    2. Разделите выборку;
    3. Обучить на обучающей выборке одиночное дерево, случайный лес и реализовать бустинг для решающих деревьев (AdaBoost, CatBoost, XGBoost);
    4. Сравните производительность моделей с помощью classification_report (sklearn.metrics);
    5. Укажите, какой класс модели определяют хуже всего, и предположите, почему.

Код программы:

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler, LabelEncoder
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier, AdaBoostClassifier
from xgboost import XGBClassifier
from catboost import CatBoostClassifier
from sklearn.metrics import classification_report, confusion_matrix,
ConfusionMatrixDisplay
import matplotlib.pyplot as plt
import seaborn as sns

df = pd.read_csv("glass.csv")

X = df.drop("Type", axis=1)

from sklearn.preprocessing import LabelEncoder
le = LabelEncoder()
y = le.fit_transform(df["Type"])

X_train, X_test, y_train, y_test = train_test_split(
   X, y, test_size=0.3, random_state=42, stratify=y
)
```

```
models = {
   "Decision Tree": DecisionTreeClassifier(random_state=42),
   "Random Forest": RandomForestClassifier(n_estimators=200,
random_state=42),
   "AdaBoost": AdaBoostClassifier(n_estimators=200, random_state=42),
   "XGBoost": XGBClassifier(n_estimators=200, random_state=42,
eval_metric='mlogloss', use_label_encoder=False),
   "CatBoost": CatBoostClassifier(iterations=200, verbose=0, random_seed=42)
}

results = {}

for name, model in models.items():
   model.fit(X_train, y_train)
   y_pred = model.predict(X_test)
   acc = accuracy_score(y_test, y_pred)
   results[name] = {"model": model, "acc": acc, "pred": y_pred}

plt.figure(figsize=(8,5))
sns.barplot(x=list(results.keys()), y=[r["acc"] for r in results.values()],
palette="viridis")
plt.title("Сравнение точности моделей", fontsize=14)
plt.ylabel("Accuracy")
plt.ylim(0, 1)
plt.xticks(rotation=20)
plt.show()

for name, res in results.items():
   cm = confusion_matrix(y_test, res["pred"])
   disp = ConfusionMatrixDisplay(cm, display_labels=np.unique(y))
   disp.plot(cmap="Blues", values_format='d')
   plt.title(f"Confusion Matrix: {name}")
   plt.show()

plt.figure(figsize=(35, 15))
plot_tree(results["Decision Tree"]["model"],
        feature_names=X.columns,
        class_names=[str(c) for c in np.unique(y)],
        filled=True, rounded=True, fontsize=8)
plt.title("Decision Tree Structure")
plt.show()

def plot_feature_importance(model, model_name):
   if hasattr(model, "feature_importances_"):
      importances = model.feature_importances_
      indices = np.argsort(importances)[::-1]
      plt.figure(figsize=(8, 4))
      sns.barplot(x=importances[indices], y=np.array(X.columns)[indices],
palette="mako")
      plt.title(f"Feature Importance: {model_name}")
```

```
        plt.xlabel("Importance")
        plt.ylabel("Feature")
        plt.show()

for name, res in results.items():
    plot_feature_importance(res["model"], name)

print("Сравнение точности:")
for name, res in results.items():
    print(f"{name:15s} — Accuracy: {res['acc']:.4f}")

best_model = max(results.items(), key=lambda x: x[1]['acc'])
print(f"\nЛучшая модель: {best_model[0]} с точностью
{best_model[1]['acc']:.4f}")

from sklearn.metrics import classification_report

print("\n=== Classification Reports ===")
for name, res in results.items():
    print(f"\n--- {name} ---")
    print(classification_report(y_test, res["pred"], target_names=[str(c) for c in
np.unique(y)]))
```

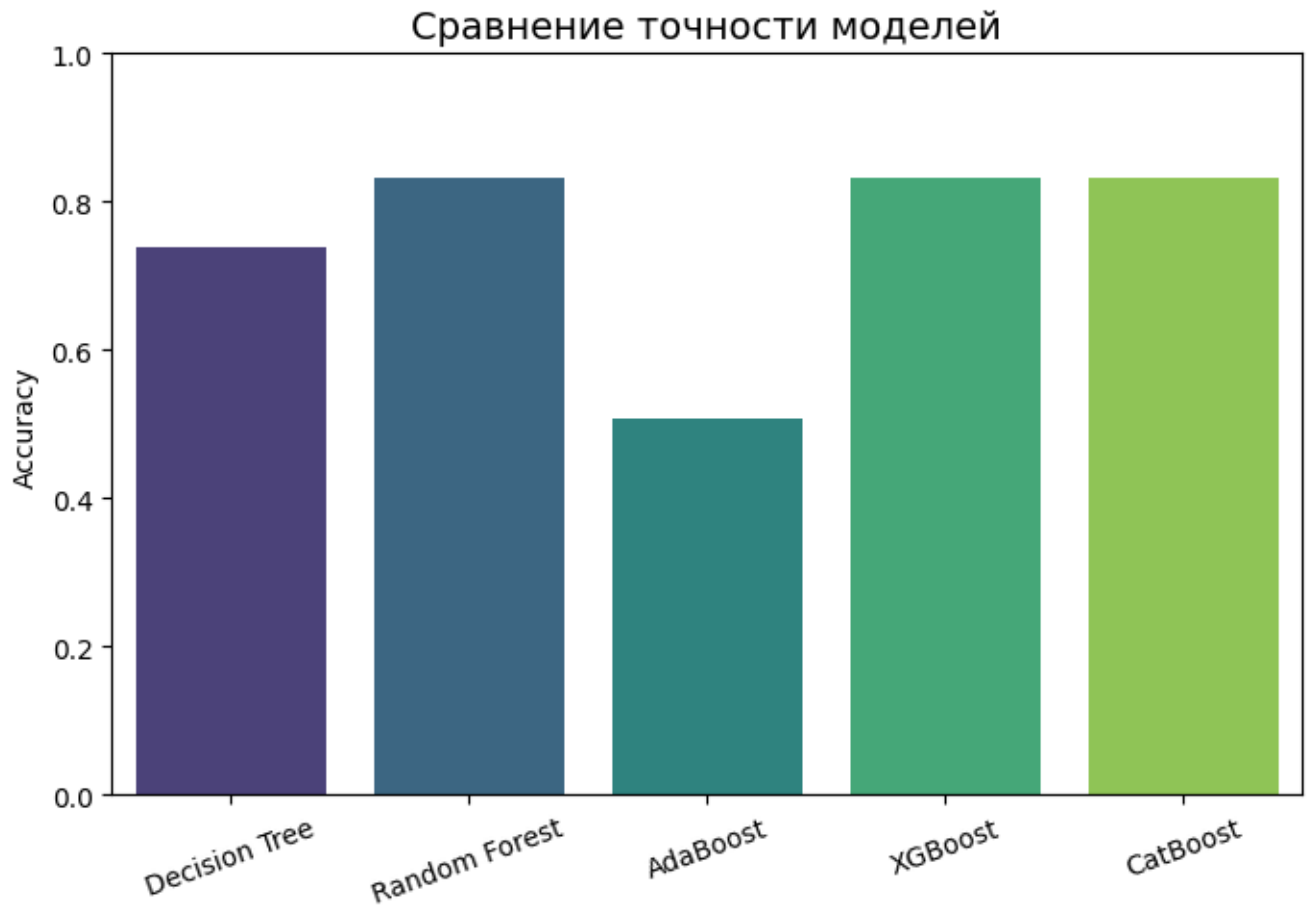

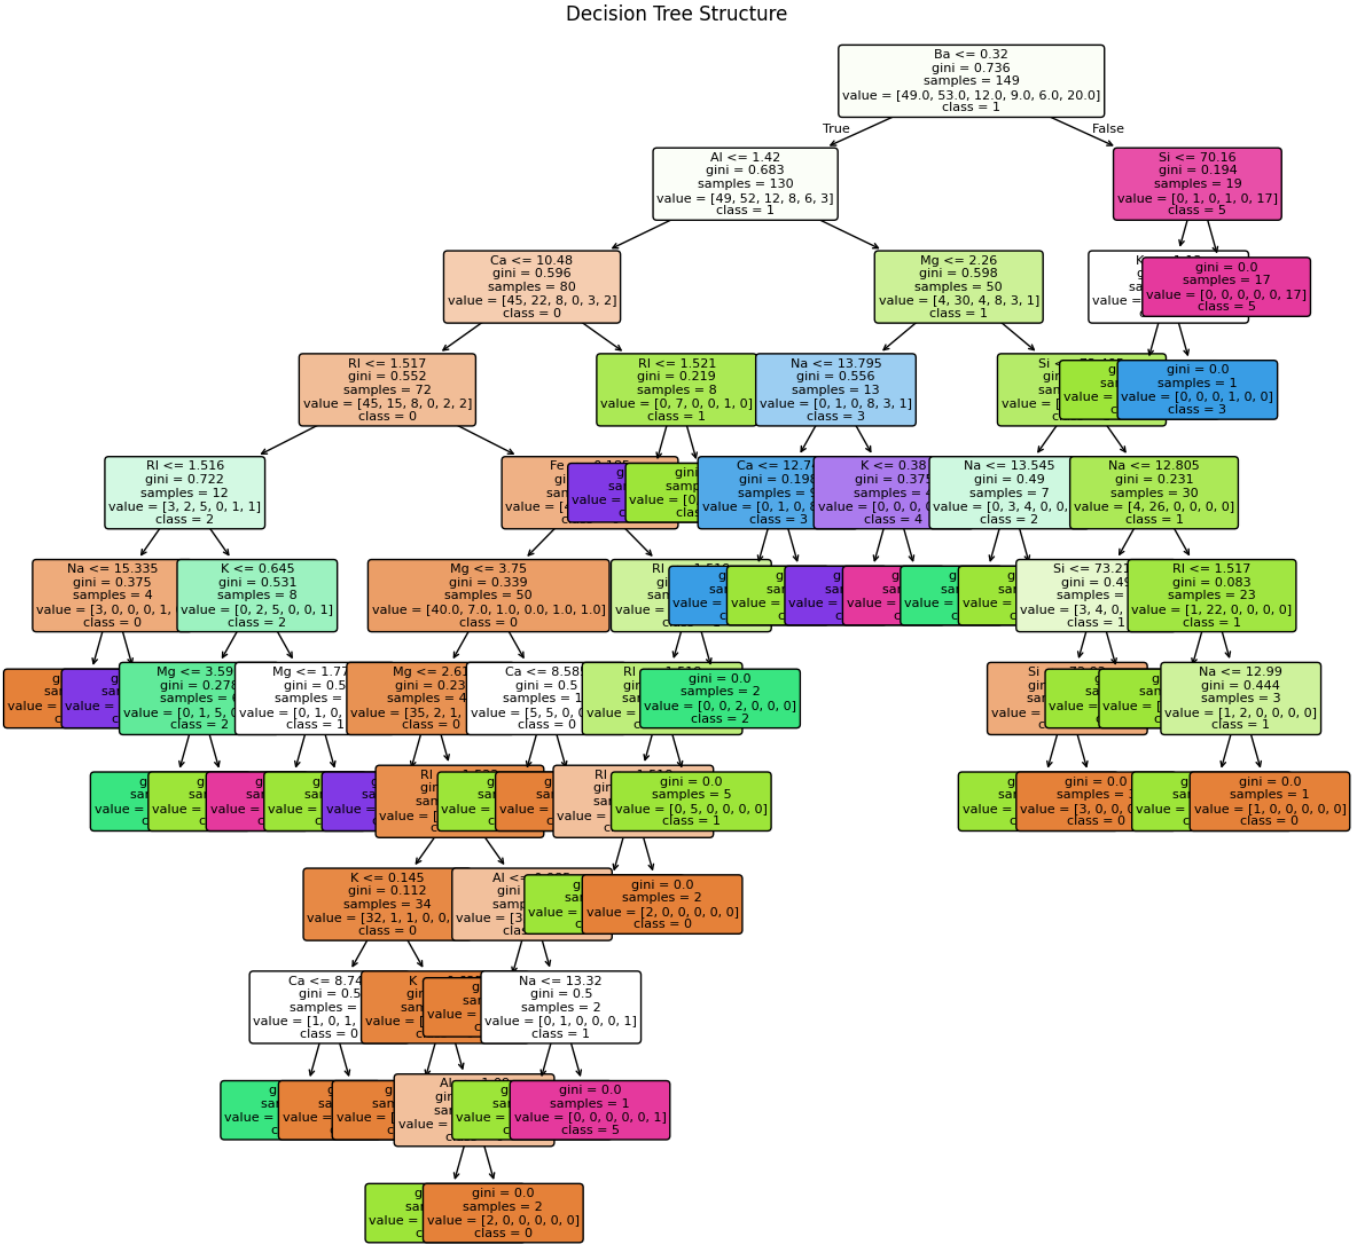
Decision Tree Structure
Ba <= 0.32
gini = 0.736
samples = 149
value = [49.0, 53.0, 12.0, 9.0, 6.0, 20.0]
class = 1
True
False
Al <= 1.42
gini = 0.683
samples = 130
value = [49, 52, 12, 8, 6, 3]
class = 1
Si <= 70.16
gini = 0.194
samples = 19
value = [0, 1, 0, 1, 0, 17]
class = 5
Ca <= 10.48
gini = 0.596
samples = 80
value = [45, 22, 8, 0, 3, 2]
class = 0
Mg <= 2.26
gini = 0.598
samples = 50
value = [4, 30, 4, 8, 3, 1]
class = 1
gini = 0.0
samples = 17
value = [0, 0, 0, 0, 0, 17]
class = 5
RI <= 1.517
gini = 0.552
samples = 72
value = [45, 15, 8, 0, 2, 2]
class = 0
RI <= 1.521
gini = 0.219
samples = 8
value = [0, 7, 0, 0, 1, 0]
class = 1
Na <= 13.795
gini = 0.556
samples = 13
value = [0, 1, 0, 8, 3, 1]
class = 3
gini = 0.0
samples = 1
value = [0, 0, 0, 1, 0, 0]
class = 3
RI <= 1.516
gini = 0.722
samples = 12
value = [3, 2, 5, 0, 1, 1]
class = 2
Ca <= 12.7
gini = 0.198
samples = 9
value = [0, 1, 0, 8
class = 3
K <= 0.38
gini = 0.375
samples = 4
value = [0, 0, 0, 0
class = 4
Na <= 13.545
gini = 0.49
samples = 7
value = [0, 3, 4, 0, 0,
class = 2
Na <= 12.805
gini = 0.231
samples = 30
value = [4, 26, 0, 0, 0, 0]
class = 1
Na <= 15.335
gini = 0.375
samples = 4
value = [3, 0, 0, 0, 1,
class = 0
K <= 0.645
gini = 0.531
samples = 8
value = [0, 2, 5, 0, 0, 1]
class = 2
Mg <= 3.75
gini = 0.339
samples = 50
value = [40.0, 7.0, 1.0, 0.0, 1.0, 1.0]
class = 0
Si <= 73.21
gini = 0.49
samples = 3
value = [3, 4, 0,
class = 1
RI <= 1.517
gini = 0.083
samples = 23
value = [1, 22, 0, 0, 0, 0]
class = 1
Mg <= 3.59
gini = 0.278
samples = 6
value = [0, 1, 5, 0
class = 2
Mg <= 1.77
gini = 0.5
samples = 2
value = [0, 1, 0,
class = 1
Mg <= 2.61
gini = 0.23
samples = 4
value = [35, 2, 1,
class = 0
Ca <= 8.58
gini = 0.5
samples = 1
value = [5, 5, 0, 0
class = 0
gini = 0.0
samples = 2
value = [0, 0, 2, 0, 0, 0]
class = 2
Na <= 12.99
gini = 0.444
samples = 3
value = [1, 2, 0, 0, 0, 0]
class = 1
gini = 0.0
samples = 5
value = [0, 5, 0, 0, 0, 0]
class = 1
gini = 0.0
samples = 3
value = [3, 0, 0, 0
class = 0
gini = 0.0
samples = 1
value = [1, 0, 0, 0, 0, 0]
class = 0
K <= 0.145
gini = 0.112
samples = 34
value = [32, 1, 1, 0, 0,
class = 0
gini = 0.0
samples = 2
value = [2, 0, 0, 0, 0, 0]
class = 0
Ca <= 8.74
gini = 0.5
samples = 4
value = [1, 0, 1,
class = 0
Na <= 13.32
gini = 0.5
samples = 2
value = [0, 1, 0, 0, 0, 1]
class = 1
gini = 0.0
samples = 1
value = [0, 0, 0, 0, 0, 1]
class = 5
gini = 0.0
samples = 2
value = [2, 0, 0, 0, 0, 0]
class = 0

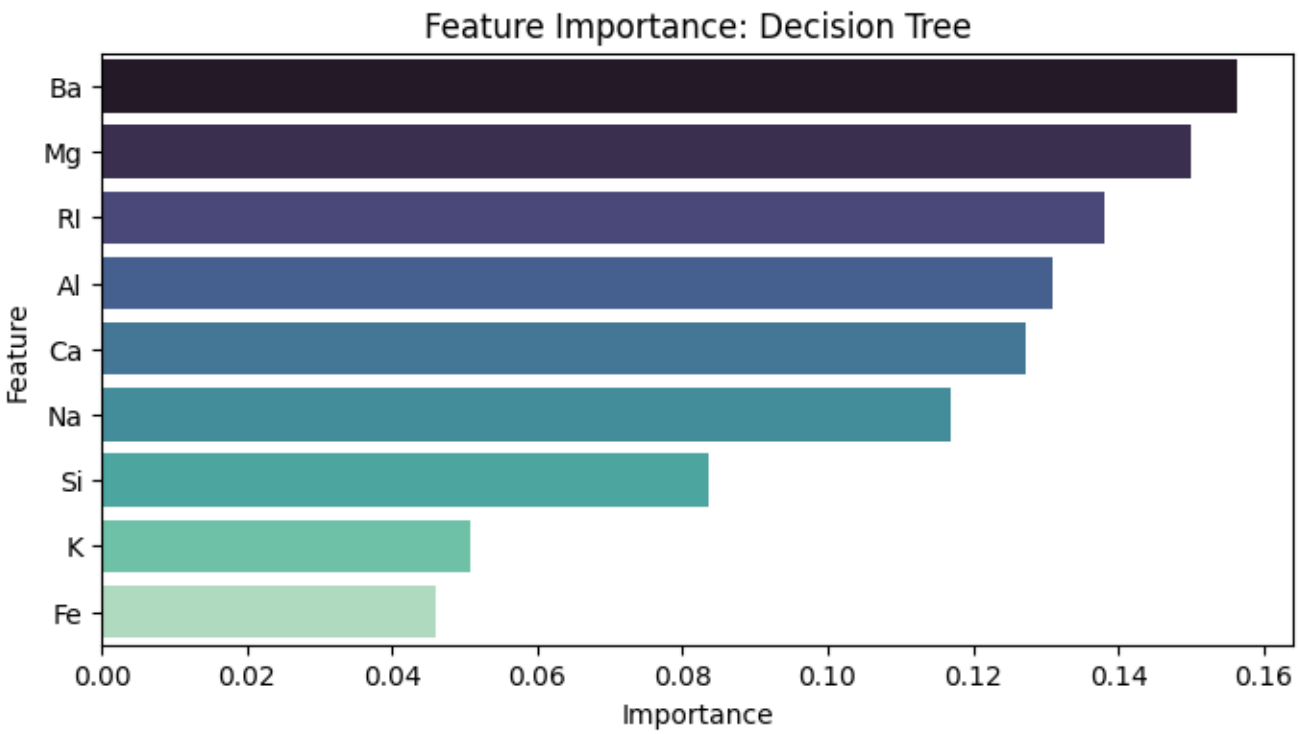
Feature Importance: Decision Tree
Ba
Mg
RI
Al
Ca
Na
Si
K
Fe
Feature
0.00
0.02
0.04
0.06
0.08
0.10
0.12
0.14
0.16
Importance

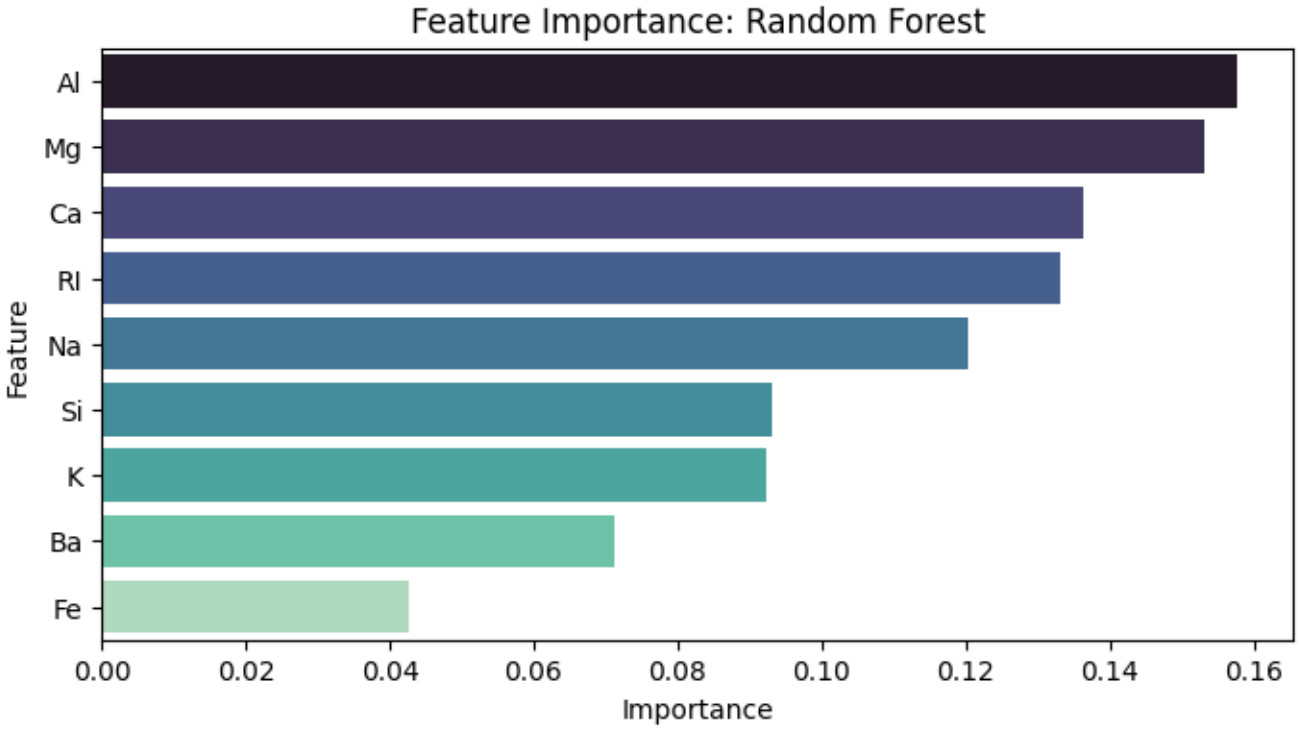
Feature Importance: Random Forest
Al
Mg
Ca
RI
Na
Si
K
Ba
Fe
Feature
0.00
0.02
0.04
0.06
0.08
0.10
0.12
0.14
0.16
Importance

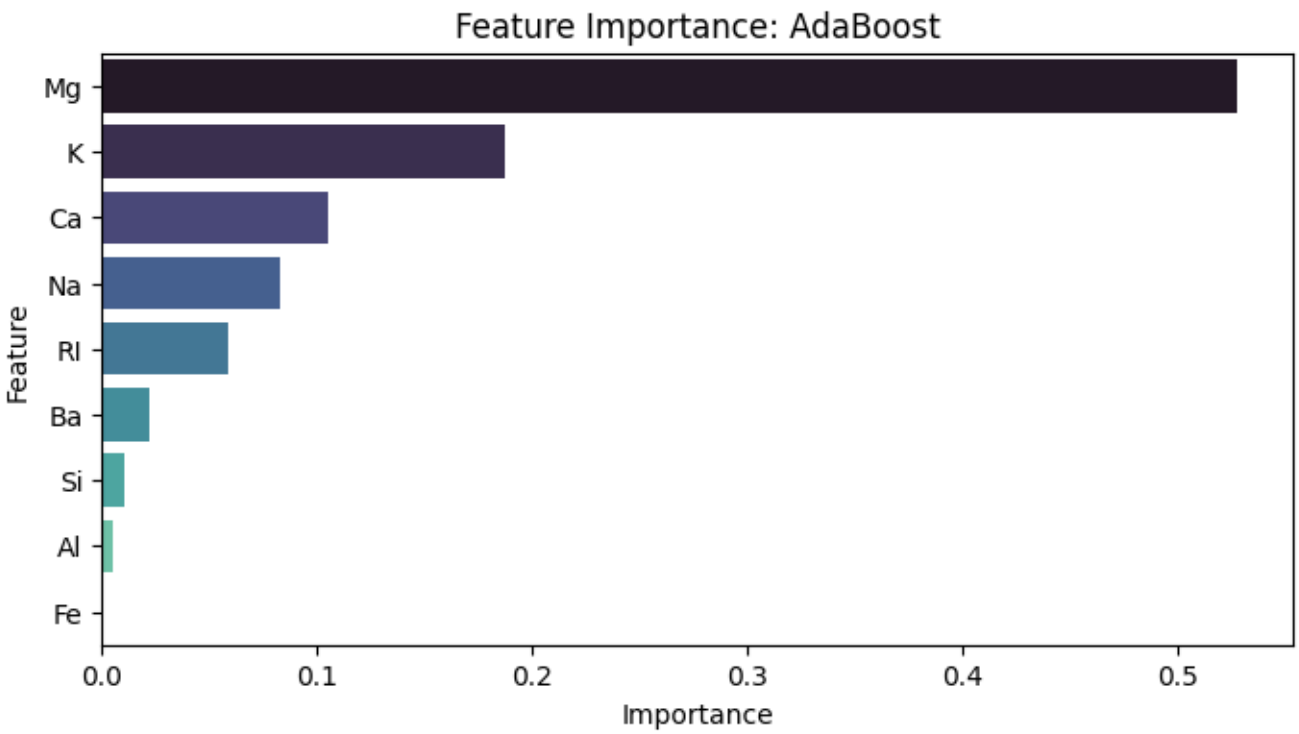
Feature Importance: AdaBoost
Mg
K
Ca
Na
RI
Ba
Si
Al
Fe
Feature
0.0
0.1
0.2
0.3
0.4
0.5
Importance

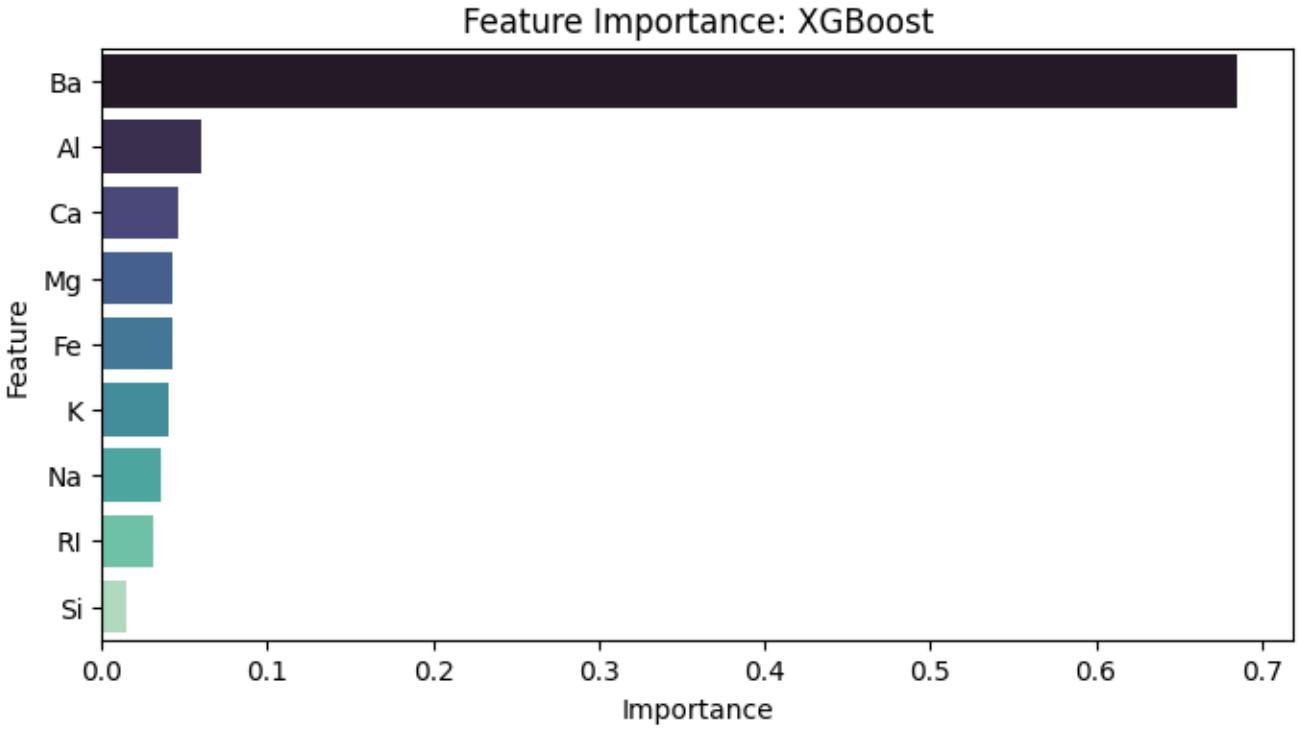
Feature Importance: XGBoost
Ba
Al
Ca
Mg
Fe
K
Na
RI
Si
Feature
0.0
0.1
0.2
0.3
0.4
0.5
0.6
0.7
Importance

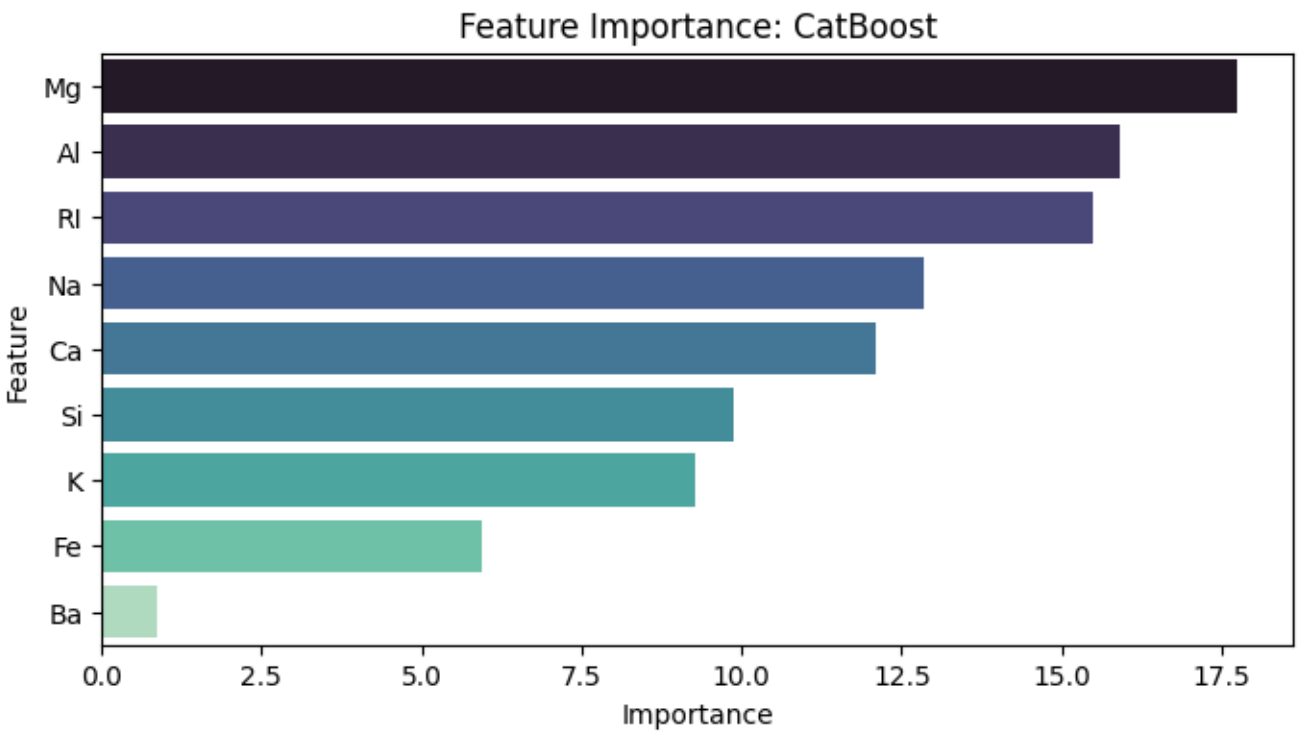

Сравнение точности:
Decision Tree — Accuracy: 0.7385
Random Forest — Accuracy: 0.8308
AdaBoost — Accuracy: 0.5077
XGBoost — Accuracy: 0.8308
CatBoost — Accuracy: 0.8308

Лучшая модель: Random Forest с точностью 0.8308
=== Classification Reports ===

--- Decision Tree ---

	precision	recall	f1-score	support
0	0.78	0.86	0.82	21
1	0.82	0.61	0.70	23
2	0.33	0.40	0.36	5
3	0.75	0.75	0.75	4
4	0.50	0.67	0.57	3
5	0.82	1.00	0.90	9
accuracy			0.74	65
macro avg	0.67	0.71	0.68	65
weighted avg	0.75	0.74	0.74	65

--- Random Forest ---

	precision	recall	f1-score	support
0	0.80	0.95	0.87	21
1	0.86	0.78	0.82	23

2	1.00	0.40	0.57	5
3	0.60	0.75	0.67	4
4	0.75	1.00	0.86	3
5	1.00	0.89	0.94	9
accuracy			0.83	65
macro avg	0.83	0.80	0.79	65
weighted avg	0.85	0.83	0.83	65

--- AdaBoost ---

	precision	recall	f1-score	support
0	0.56	0.67	0.61	21
1	0.53	0.35	0.42	23
2	0.00	0.00	0.00	5
3	0.25	0.50	0.33	4
4	0.67	0.67	0.67	3
5	0.88	0.78	0.82	9
accuracy			0.51	65
macro avg	0.48	0.49	0.48	65
weighted avg	0.54	0.51	0.51	65

--- XGBoost ---

	precision	recall	f1-score	support
0	0.83	0.90	0.86	21
1	0.94	0.74	0.83	23
2	0.50	0.40	0.44	5
3	0.67	1.00	0.80	4
4	0.75	1.00	0.86	3
5	0.90	1.00	0.95	9
accuracy			0.83	65
macro avg	0.76	0.84	0.79	65
weighted avg	0.84	0.83	0.83	65

--- CatBoost ---

	precision	recall	f1-score	support
0	0.83	0.95	0.89	21
1	0.86	0.78	0.82	23
2	0.75	0.60	0.67	5
3	0.75	0.75	0.75	4
4	0.67	0.67	0.67	3
5	0.89	0.89	0.89	9
accuracy			0.83	65

macro avg	0.79	0.77	0.78	65
weighted avg	0.83	0.83	0.83	65

На датасете Glass Identification AdaBoost показал худшую точность (0.51).
Основная причина - многоклассовая структура и малая представленность некоторых типов стекла.
Метод усиливает ошибки редких и пересекающихся объектов, что приводит к переобучению на этих сложных примерах.
В отличие от него, Random Forest и продвинутые бустинги (XGBoost, CatBoost) усредняют ошибки или используют регуляризацию, что делает их более устойчивыми.

Вывод: На практике сравнил работу нескольких алгоритмов одиночного дерева решений, случайного леса и бустинга для деревьев решений.