

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №4
По дисциплине: «ИАД»
Тема: «**Предобучение нейронных сетей с использованием RBM**»

Выполнил:
Студент 4 курса
Группы ИИ-23
Ежевский Е.Р.
Проверила:
Андренко К.В.

Брест 2025

Цель: научиться осуществлять предобучение нейронных сетей с помощью RBM

Общее задание

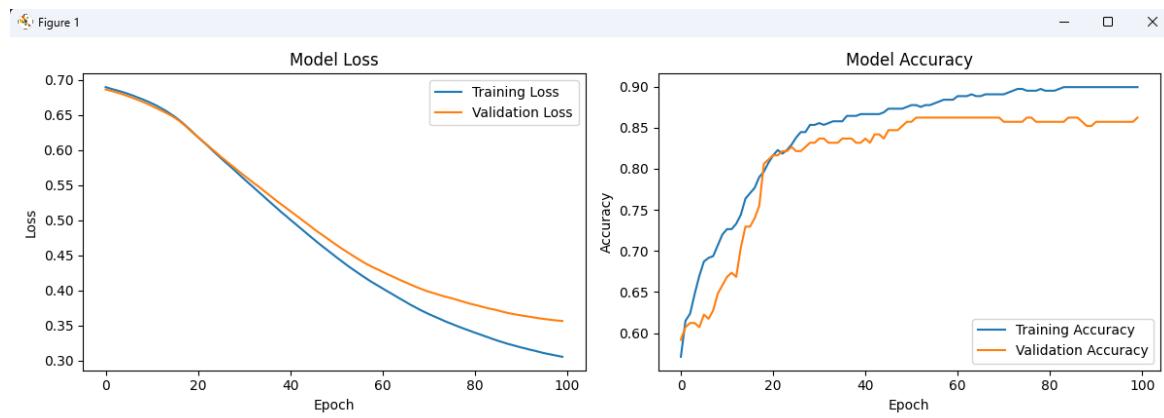
1. Взять за основу нейронную сеть из лабораторной работы №3. Выполнить обучение с предобучением, используя стек ограниченных машин Больцмана (RBM – Restricted Boltzmann Machine), алгоритм которого изложен в лекции. Условие останова (например, по количеству эпох) при обучении отдельных слоев как RBM выбрать самостоятельно.
2. Сравнить результаты, полученные при
 - обучении без предобучения (ЛР 3);
 - обучении с предобучением, используя автоэнкодерный подход (ЛР3);
 - обучении с предобучением, используя RBM.
3. Обучить модели на данных из ЛР 2, сравнить результаты по схеме из пункта 2;
4. Сделать выводы, оформить отчет по выполненной работе, загрузить исходный код и отчет в соответствующий репозиторий на github.

Задание по вариантам

№	Выборка	Тип задачи	Целевая переменная
1	https://archive.ics.uci.edu/dataset/27/credit+approval	классификация	+/-

Код программы:

Модель без предобучения:

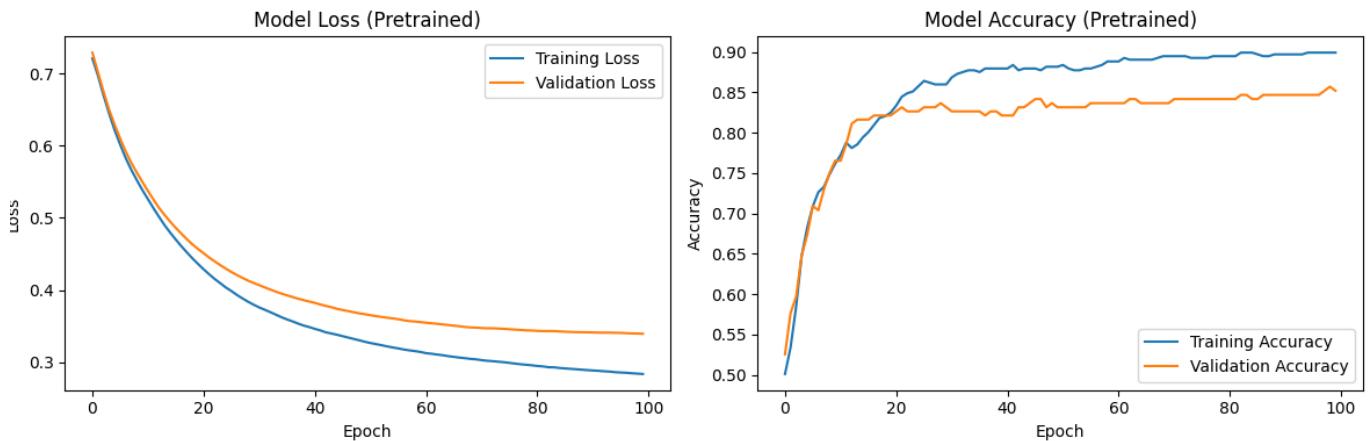


```
Classification Report:  
precision    recall    f1-score   support  
0            0.84     0.85      0.84      86  
1            0.88     0.87      0.88     110  
  
accuracy          0.86  
macro avg       0.86     0.86      0.86     196  
weighted avg    0.86     0.86      0.86     196
```

```
Confusion Matrix:
```

```
[[73 13]  
[14 96]]
```

Модель с предобучением на автоэнодере:



Classification Report (Pretrained):				
	precision	recall	f1-score	support
0	0.82	0.85	0.83	86
1	0.88	0.85	0.87	110
accuracy			0.85	196
macro avg		0.85	0.85	196
weighted avg		0.85	0.85	196
Confusion Matrix (Pretrained):				
[[73 13] [16 94]]				

Предобучение с машинами Больцмана:

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import MinMaxScaler, LabelEncoder
from sklearn.impute import SimpleImputer
from keras.models import Sequential
from keras.layers import Dense
from keras.optimizers import Adam
import matplotlib.pyplot as plt

data = pd.read_csv('crx.data', header=None, na_values='?')

cols = [f"A{i}" for i in range(1,17)]
data.columns = cols

X = data.drop('A16', axis=1)
y = data['A16']

y = y.map({'+": 1, "-": 0})

num_cols = X.select_dtypes(include=['float64', 'int64']).columns.tolist()
for c in X.columns:
    try:
```

```

X[c] = pd.to_numeric(X[c])
if c not in num_cols:
    num_cols.append(c)
except:
    pass

cat_cols = [c for c in X.columns if c not in num_cols]

imp_num = SimpleImputer(strategy='median')
X[num_cols] = imp_num.fit_transform(X[num_cols])

imp_cat = SimpleImputer(strategy='most_frequent')
X[cat_cols] = imp_cat.fit_transform(X[cat_cols])

for c in cat_cols:
    X[c] = LabelEncoder().fit_transform(X[c])

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.3, random_state=42, stratify=y
)

scaler = MinMaxScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

model = Sequential()
model.add(Dense(32, input_shape=(X_train_scaled.shape[1],),
activation='relu'))
model.add(Dense(16, activation='relu'))
model.add(Dense(8, activation='relu'))
model.add(Dense(1, activation='sigmoid'))

model.compile(optimizer=Adam(learning_rate=0.0005),
              loss='binary_crossentropy',
              metrics=['accuracy'])

history = model.fit(X_train_scaled, y_train,
                     validation_data=(X_test_scaled, y_test),
                     epochs=100,
                     batch_size=64)

plt.figure(figsize=(12, 4))

plt.subplot(1, 2, 1)
plt.plot(history.history['loss'], label='Training Loss')
plt.plot(history.history['val_loss'], label='Validation Loss')
plt.title('Model Loss')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.legend()

```

```

plt.subplot(1, 2, 2)
plt.plot(history.history['accuracy'], label='Training Accuracy')
plt.plot(history.history['val_accuracy'], label='Validation Accuracy')
plt.title('Model Accuracy')
plt.xlabel('Epoch')
plt.ylabel('Accuracy')
plt.legend()

plt.tight_layout()
plt.show()

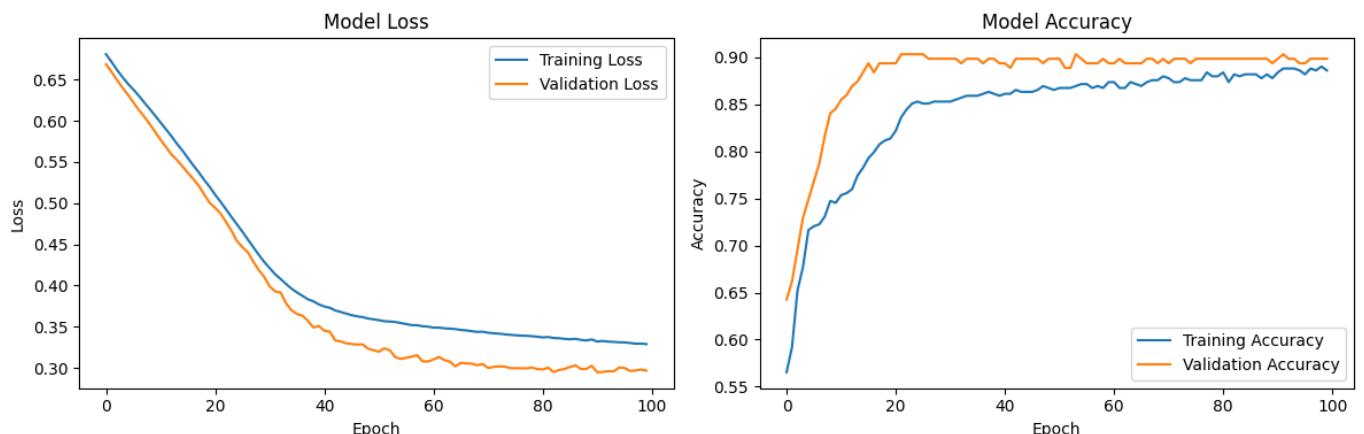
```

```
y_pred = (model.predict(X_test_scaled) > 0.5).astype(int).ravel()
```

```

from sklearn.metrics import classification_report, confusion_matrix
print("Classification Report:\n", classification_report(y_test, y_pred))
print("Confusion Matrix:\n", confusion_matrix(y_test, y_pred))

```



Classification Report:				
	precision	recall	f1-score	support
0	0.91	0.90	0.91	115
1	0.88	0.89	0.89	92
accuracy			0.90	207
macro avg	0.90	0.90	0.90	207
weighted avg	0.90	0.90	0.90	207

Confusion Matrix:

```
[[104 11]
 [ 10 82]]
```

Для задач такого типа, как кредитное scoring-моделирование в датасете Credit Approval, где объем данных ограничен, а структура признаков относительно проста, использование последовательного предобучения с применением RBM не дает значимых преимуществ по сравнению с обычной нейронной сетью. Несмотря на то, что Restricted Boltzmann Machines способны выявлять скрытые зависимости и формировать более компактные представления признаков, их эффективность проявляется преимущественно в задачах с высокой размерностью, сложными распределениями данных или при отсутствии достаточного количества размеченных примеров.

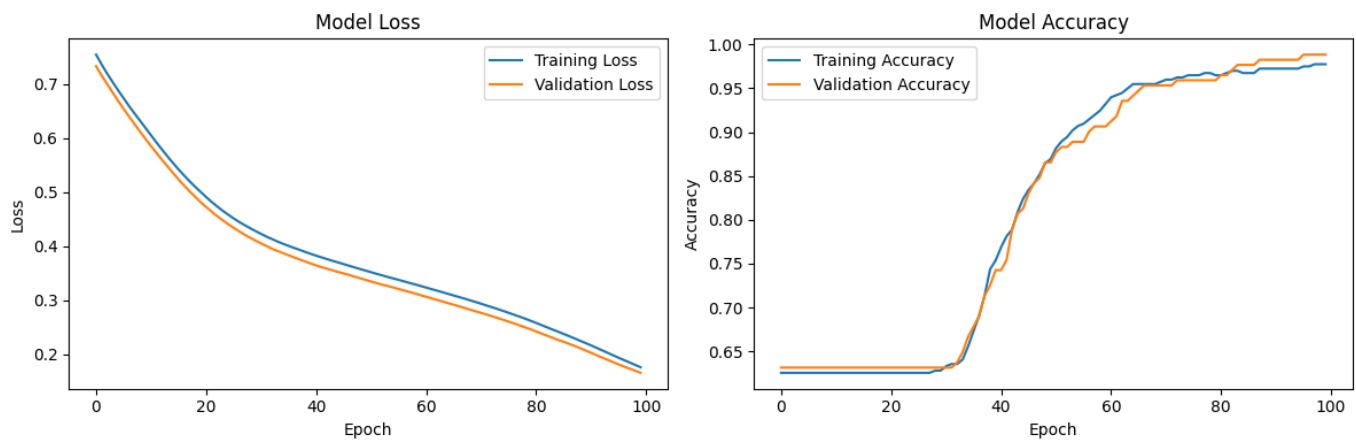
В рамках данной задачи стандартная архитектура нейронной сети демонстрирует оптимальную производительность без необходимости привлекать этапы предобучения. Модель уверенно усваивает структуру признаков, а дополнительное использование RBM усложняет процесс обучения, увеличивает вычислительные затраты и не обеспечивает ощутимого прироста качества.

Предобучение такого рода проявляет свою силу в более масштабных задачах, где данные обладают нелинейной высокой размерностью или скрытой структурой, которую сложно извлечь напрямую методом прямого обучения нейронной сети.

Таким образом, хотя включение RBM в архитектуру модели является интересным экспериментом, в условиях данного датасета наиболее эффективным, интерпретируемым и практическим решением остается классическая нейросетевая модель без дополнительных слоев предобучения.

Данные для датасета [Wisconsin Diagnostic Breast Cancer \(WDBC\)](#):

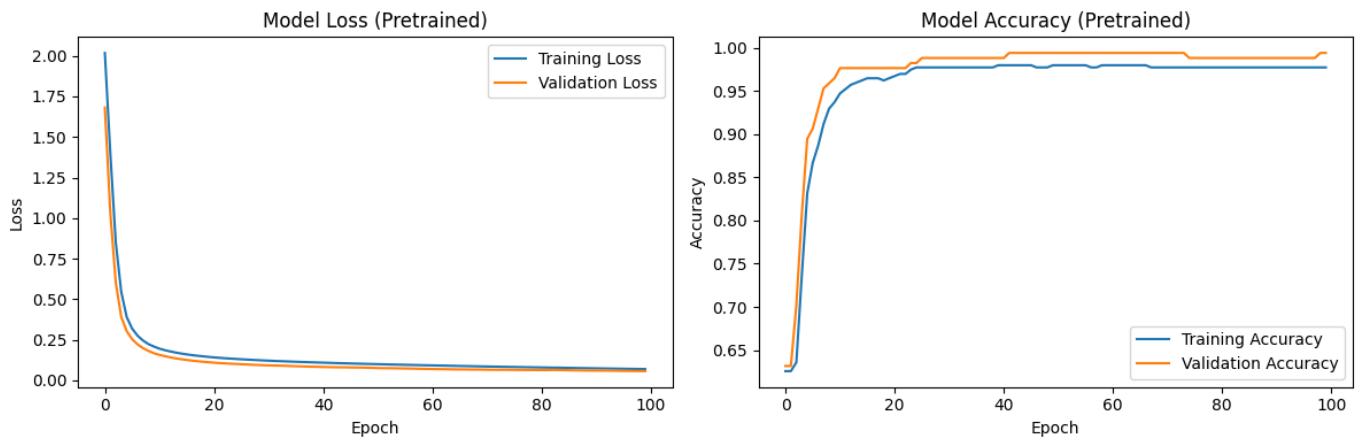
С нуля:



Classification Report:				
	precision	recall	f1-score	support
0	0.98	1.00	0.99	108
1	1.00	0.97	0.98	63
accuracy			0.99	171
macro avg	0.99	0.98	0.99	171
weighted avg	0.99	0.99	0.99	171

Confusion Matrix:	
[[108 0]	
[2 61]]	

Предтренированная на автоэнкодере:

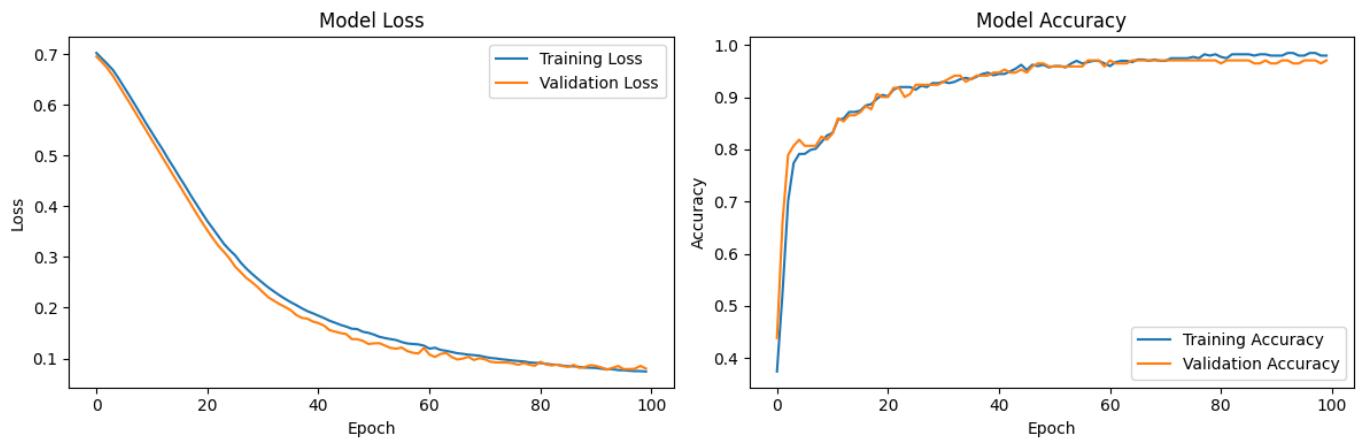


```
Classification Report (Pretrained):
precision    recall    f1-score   support
0            0.99     1.00      1.00      108
1            1.00     0.98      0.99      63

accuracy                           0.99      171
macro avg       1.00     0.99      0.99      171
weighted avg    0.99     0.99      0.99      171

Confusion Matrix (Pretrained):
[[108  0]
 [ 1 62]]
```

Предтренированная на RBM:



```
Classification Report:
precision    recall    f1-score   support
0            0.96     0.99      0.98      107
1            0.98     0.94      0.96      64

accuracy                           0.97      171
macro avg       0.97     0.96      0.97      171
weighted avg    0.97     0.97      0.97      171

Confusion Matrix:
[[106  1]
 [ 4 60]]
```

Метод предобучения на основе Restricted Boltzmann Machines (RBM) демонстрирует преимущество для решения задачи классификации с дисбалансом классов, обеспечивая более сбалансированное качество распознавания среди всех категорий.

Вывод: научился осуществлять предобучение нейронных сетей с помощью автоэнкодерного подхода